

AUDIT MÉTHODOLOGIQUE CONSTRUCTIF ET INDÉPENDANT

Rapport d'observation runtime - Kimi K3

Analyse des fragilités, éléments solides et protocoles concrets de renforcement

Auteur : Stéphane Gorius

Version : 1.1 finale

Affiliation : R&D AIzyNow

Date : 24 juillet 2026

Du signal observable à la mesure validée

Document de travail indépendant. L'identité visuelle s'inspire de la sobriété du rapport source, sans reprise du logo ni présomption d'endossement par NeoMundi.

Note d'indépendance et de bienveillance

Positionnement de l'audit

Cet audit a été réalisé à titre gracieux, dans une démarche indépendante et constructive. Il vise à renforcer la solidité méthodologique de NeoMundi, non à remettre en cause la bonne foi, les compétences ou l'intérêt du projet.

Le périmètre analysé est le rapport public « Rapport d'observation runtime - Kimi K3 », version 1.0, généré le 22 juillet 2026. L'audit ne dispose pas, à ce stade, des fichiers CSV/JSON, du code de calcul, des prompts complets ni de la documentation interne des métriques.

Principe de lecture

Une information absente du rapport public n'est pas réputée inexistante dans l'implémentation interne. Le document distingue donc systématiquement une fragilité méthodologique avérée, une documentation insuffisante et une limite déjà reconnue par NeoMundi.

- Les critiques portent sur les méthodes et les preuves accessibles, jamais sur les personnes.
- Chaque constat important est accompagné d'un protocole directement exécutable.
- Les seuils proposés sont des cibles de départ à pré-enregistrer, pas des normes universelles.
- La terminologie du rapport source est conservée lorsque cela facilite la lecture croisée.

Source principale : NeoMundi Observatory, Rapport d'observation runtime - Kimi K3, version 1.0, 20 pages [S1].

Sommaire

- 1** Synthèse exécutive
- 2** Périmètre et méthode de l'audit
- 3** Éléments solides à conserver
- 4** Carte synthétique des constats
- 5** Validité et documentation des métriques
- 6** Capacité discriminante et hypothèse d'invariant
- 7** Décisions ALLOW / FLAG et contrôles positifs
- 8** Exploitation des répétitions et stabilité
- 9** Cohérence, factualité et vérité terrain
- 10** Régimes runtime et effet de la longueur
- 11** Instrumentation du pipeline et processing time
- 12** Reproductibilité et chaîne de preuve
- 13** Identité du modèle et provenance API
- 14** Validation longitudinale et dérive
- 15** Plan d'exécution sur 30 jours
- 16** Critères d'acceptation et formulations recommandées
- 17** Conclusion
- A-B** Annexes opérationnelles et bibliographie

1. Synthèse exécutive

Le rapport constitue une base d’observabilité intéressante. La prochaine étape est la validation métrologique.

5 forces méthodologiques à préserver	10 axes de renforcement identifiés	4 priorités immédiates à fort impact
30 j feuille de route proposée	0 mise en cause des personnes	1 objectif : rendre la méthode défendable

Le rapport NeoMundi repose sur un corpus conséquent de 1 200 exécutions, une structure de répétition explicite, des identifiants de trace et une séparation utile entre dimensions de performance et dimensions comportementales. Sa prudence éditoriale, notamment la formule « signal mesuré, pas verdict », est un point fort [S1, p. 3-7 et 18-19].

La fragilité principale ne tient pas à la collecte technique, mais au passage de la télémétrie vers des affirmations de stabilité, cohérence, factualité ou gouvernance. Les définitions opérationnelles, données de calibration, contrôles positifs, taux d’erreur et procédures de validation ne sont pas publiés. Plusieurs scores sont en outre constants ou presque constants, ce qui invite à examiner d’abord l’instrument de mesure [S1, p. 8].

Conclusion centrale

NeoMundi dispose déjà d’une couche de traçabilité exploitable. Pour devenir une métrologie défendable, cette couche doit démontrer trois propriétés : validité du construit, sensibilité aux anomalies connues et reproductibilité indépendante.



Cycle minimal proposé pour passer d’un score opérationnel à une métrique validée.

Priorités immédiates

- 1. Publier un dictionnaire exécutable des métriques, avec formule, entrées, normalisation, seuils et limites.
- 2. Construire un jeu de calibration contenant des cas propres et des anomalies connues, puis mesurer les faux positifs et faux négatifs.
- 3. Exploiter les dix répétitions au niveau de chaque prompt avant toute moyenne par famille.
- 4. Séparer TTFT, TPOT, débit, post-traitement et longueur afin d’éviter que les « régimes » ne reflètent principalement le volume généré.

2. Périmètre et méthode de l’audit

Documents et éléments examinés


- Rapport NeoMundi Kimi K3, version 1.0, 20 pages [S1].
- Statistiques globales, tableaux par famille, graphiques de distribution et exemple de trace reconstructible.
- Noms des artefacts et empreintes SHA-256 indiqués en annexe, sans accès aux fichiers correspondants.
- Littérature primaire sur l’évaluation répétée, la factualité, les juges automatiques, la fiabilité agentique et les métriques d’inférence [R1-R8].

Grille de qualification

Qualification	Définition utilisée dans cet audit
Solide à conserver	Élément correctement documenté et utile pour la suite.
Limite déjà assumée	Restriction explicitement reconnue par NeoMundi, à maintenir dans les futures versions.
Documentation insuffisante	La méthode peut exister, mais le rapport ne permet pas de l’auditer ou de la reproduire.
Fragilité méthodologique	Le dispositif publié ne permet pas encore de soutenir l’interprétation proposée.
Anomalie à investiguer	Distribution ou valeur surprenante qui peut provenir d’un choix technique, d’une saturation ou d’un défaut.

Principe d’audit

Chaque axe suit la même séquence : observation dans le rapport, risque d’interprétation, protocole de renforcement, critère de décision et livrable attendu. Cette structure évite les recommandations abstraites du type « améliorer la robustesse » sans préciser comment.



Priorisation proposée selon l’impact méthodologique et l’effort de mise en œuvre.

3. Éléments solides à conserver

Point important

L’audit ne part pas d’une page blanche. Plusieurs choix du rapport constituent déjà une bonne base d’ingénierie et de gouvernance.


Élément	Pourquoi le conserver
Périmètre prudent	Le rapport précise ce qu’il observe et ce qu’il ne détermine pas directement [S1, p. 4].
Répétitions explicites	120 situations répétées 10 fois, ce qui rend possible une véritable analyse intra-prompt [S1, p. 5].
Qualité de corpus	La relance ciblée d’une exécution incomplète, le contrôle des doublons et la couverture finale sont documentés [S1, p. 6].
Dimensions séparées	La décision de ne pas fusionner automatiquement stabilité, factualité, cohérence et performance dans un score unique est saine [S1, p. 7].
Traçabilité technique	Request ID, trace ID, versions de mesure et artefacts nommés facilitent l’investigation [S1, p. 14-15 et 20].
Limites explicites	Le rapport rappelle que stabilité et cohérence ne garantissent ni vérité ni exactitude [S1, p. 18].

Renforcement éditorial simple

Ces éléments devraient être regroupés dans une future section « garanties actuelles du protocole ». Cette présentation montrerait clairement ce qui est déjà maîtrisé, avant d’exposer ce qui reste en validation.

4. Carte synthétique des constats

Axe	Qualification	Priorité	Action principale
Définition des métriques	Documentation insuffisante	P1	Publier formules, entrées, normalisation et limites.
Cohérence = 1,000	Anomalie à investiguer	P1	Jeu calibré de contradictions et mesure F1 / sensibilité.
Runtime R = 0,600	Anomalie à investiguer	P1	Test d'invariance et de sensibilité par perturbations contrôlées.
0 FLAG / 1 200	Fragilité méthodologique	P1	Contrôles positifs, négatifs, abstention et matrice de confusion.
10 répétitions	Sous-exploité	P1	Analyse intra-prompt, accord des conclusions et dispersion.
Factualité	Documentation insuffisante	P1	Décomposition en faits atomiques et vérité terrain sourcée.
Régimes runtime	Interprétation à consolider	P2	Neutraliser longueur, TTFT et TPOT avant clustering.
Processing time	Anomalie à investiguer	P2	Horodatage de chaque étape du pipeline.
Reproductibilité	Partielle	P1	Publier paquet minimal exécutable et instructions.
Identité modèle	Insuffisante	P2	Révision, endpoint, paramètres et empreinte fournisseur.
Longitudinal	Limite assumée	P3	Vagues ancrées et détection de dérive.



Étendue publiée des scores sur une échelle commune de 0 à 1. Une faible étendue ne prouve pas un défaut, mais impose un test de sensibilité.

5. Validité et documentation des métriques

CONSTAT PRINCIPAL

Le rapport nomme des métriques de stabilité, cohérence, risque sémantique, factualité, densité informationnelle et efficience, mais ne fournit ni définition mathématique, ni exemples de calcul, ni calibration, ni incertitude. L’annexe liste les colonnes et les numéros de version sans rendre les scores auditable [S1, p. 7-8 et 20].

Distinction essentielle

Versionner une métrique garantit sa traçabilité logicielle. Cela ne démontre pas sa validité, c’est-à-dire qu’elle mesure bien le phénomène annoncé.

Proposition 1 - Dictionnaire exécutable des métriques

Élément	Proposition directement exécutable
Objectif	Rendre chaque score compréhensible, testable et reproductible.
Dispositif	Créer une fiche par métrique contenant : construit visé, entrées, formule ou pseudo-code, normalisation, bornes, seuils, cas limites, dépendances, version et exemples numériques complets.
Mesures	Test unitaire sur 10 cas simples, test de monotonie, test de bornes, test de valeurs manquantes, test de sensibilité à une perturbation connue.
Critère de décision	Une tierce personne doit pouvoir recalculer exactement le score à partir d’une ligne brute et de la fiche de définition.
Livrable	Répertoire /metric-cards/ et notebook de démonstration exécutable.
Effort indicatif	2 à 4 jours pour les métriques déjà implémentées.

Gabarit minimal de fiche métrique

Champ	Contenu attendu
Nom et version	Ex. coherence_score v3.0.0.
Construit visé	Cohérence locale, globale, conformité au prompt, ou autre.
Entrées	Prompt, réponse, références, embeddings, modèle juge, paramètres.
Transformation	Formule, pseudo-code ou code de référence.
Sortie	Échelle, bornes, sens des valeurs, traitement des NA.
Seuils	Méthode de choix, jeu de calibration, date de verrouillage.
Validité connue	Accord humain, faux positifs, faux négatifs, domaines testés.
Limites	Langue, longueur, style, dépendance au juge ou à la source.

6. Capacité discriminante et hypothèse d'invariant

Dans les résultats globaux, la cohérence vaut 1,000 pour les 1 200 observations, le Runtime R vaut 0,600 pour toutes les observations et la stabilité se situe presque entièrement à 0,923 [S1, p. 8]. Ces distributions peuvent refléter une réelle homogénéité, mais aussi une saturation, un arrondi, une branche constante, un seuil trop permissif ou une faible sensibilité.

Sur le terme « invariant »

Un invariant opérationnel utile doit rester stable face aux variables nuisibles, tout en réagissant aux dégradations qu'il prétend détecter. Une simple constante est stable, mais n'apporte aucune information décisionnelle.

Proposition 2 - Banc de sensibilité et d'ablation

Élément	Proposition directement exécutable
Objectif	Vérifier que chaque score varie dans le bon sens lorsque le phénomène ciblé est modifié.
Dispositif	Créer 40 réponses de base puis produire 4 niveaux de dégradation contrôlée : contradiction, erreur factuelle, perte d'information, non-respect de consigne. Modifier séparément la longueur, la latence artificielle et le coût estimé comme variables nuisibles.
Mesures	Courbes dose-réponse, corrélation de Spearman avec le niveau de dégradation, effet standardisé, taux de saturation et variance.
Critère de décision	Pré-enregistrer les comportements attendus. À titre de cible initiale : monotonie correcte sur au moins 80 % des séries et AUC supérieure à 0,80 pour distinguer propre / dégradé.
Livrable	Rapport de sensibilité par métrique, avec graphiques et cas d'échec.
Effort indicatif	3 à 5 jours, hors annotation humaine.

Matrice concrète pour Runtime R

Expérience	Variable modifiée	Ce qui doit rester stable	Réponse attendue de R
A	Paraphrase sans changement de sens	Qualité et risque	Variation faible.
B	Latence réseau artificielle +5 s	Contenu sémantique	Variation conforme à la composante latence, si elle existe.
C	Erreur factuelle injectée	Longueur et latence	Dégradation si R prétend intégrer la fiabilité.
D	Réponse deux fois plus longue mais équivalente	Conclusion	Absence de pénalité non justifiée.

7. Décisions ALLOW / FLAG et contrôles positifs

Le corpus final contient 1 200 décisions ALLOW et aucun FLAG. Cette observation ne permet pas, à elle seule, de conclure que le modèle n’a produit aucune anomalie. Elle peut également refléter des seuils très permissifs ou une faible sensibilité du système [S1, p. 3, 8 et 13].

Règle d’évaluation

Un détecteur ne peut être validé sur un corpus dans lequel on ignore si des cas positifs sont présents. Il faut introduire des anomalies connues et vérifier qu’elles sont détectées.

Proposition 3 - Challenge set ALLOW / WARN / FLAG / ABSTAIN

Élément	Proposition directement exécutable
Objectif	Mesurer la capacité réelle du système de gouvernance à distinguer les cas acceptables, douteux et critiques.
Dispositif	Construire 240 cas : 80 contrôles propres, 40 contradictions, 40 erreurs factuelles, 20 consignes violées, 20 réponses médicales risquées, 20 surpromesses juridiques et 20 incidents techniques ou flux incomplets. Séparer 60 % développement, 20 % validation et 20 % test aveugle.
Mesures	Matrice de confusion, précision, rappel, F1, courbes précision-rappel, taux d’abstention, résultats par famille et coût des faux négatifs.
Critère de décision	Seuils choisis sur développement puis verrouillés avant le test. Pour les catégories à haut risque, privilégier le rappel et prévoir ABSTAIN lorsque la confiance est insuffisante.
Livrable	Jeu de contrôle versionné, labels, protocole d’annotation et rapport aveugle.
Effort indicatif	5 à 8 jours selon le niveau d’expertise métier.

Pourquoi ajouter WARN et ABSTAIN

L’exemple publié signale une instabilité sémantique de 0,90 au-dessus du seuil d’avertissement, tout en conservant la décision ALLOW [S1, p. 15]. Un état WARN permettrait de rendre visible cette tension. ABSTAIN évite de forcer une décision binaire lorsque la métrique n’est pas suffisamment fiable.

8. Exploitation des répétitions et mesure de la stabilité

La répétition de chaque situation dix fois est un choix prometteur. Toutefois, le rapport agrège principalement les résultats par famille et ne montre pas la dispersion entre les dix réponses d’un même prompt, alors que c’est le niveau naturel pour étudier la stabilité [S1, p. 5 et 9-12].

Proposition 4 - Analyse intra-prompt en quatre couches

Couche	Mesure directement calculable
Décision	Pourcentage des 10 répétitions partageant la même conclusion ou action recommandée.
Faits	Accord sur les nombres, entités, dates et affirmations atomiques.
Logique	Taux d’entaillement, neutralité et contradiction entre paires de réponses.
Sémantique	Dispersion d’embeddings, nombre de clusters et distance à la réponse médiane.

Élément	Proposition directement exécutable
Objectif	Séparer la stabilité comportementale de la simple similarité lexicale.
Dispositif	Réutiliser les 120 × 10 sorties existantes. Calculer les quatre couches par prompt. Ajouter un sous-protocole de 30 prompts répétés à température 0,0, 0,3 et 0,7, avec paramètres publiés.
Mesures	Accord de conclusion, contradiction rate, variance des nombres, dispersion sémantique, pass^10 pour les tâches ayant une réussite binaire et modèle hiérarchique séparant variance intra/inter-prompt.
Critère de décision	La stabilité doit être rapportée par prompt avec intervalle, puis agrégée. Une moyenne unique ne doit pas masquer les prompts instables.
Livrable	Tableau 120 lignes, distribution des dix répétitions et liste priorisée des prompts instables.
Effort indicatif	2 à 4 jours si les sorties brutes sont disponibles.

Gain immédiat

Cette analyse valorise directement l’investissement déjà réalisé dans les 1 200 exécutions. Elle ne nécessite pas de relancer l’ensemble du corpus.

9. Cohérence, factualité et vérité terrain

La cohérence et la factualité sont des construits différents. Une réponse peut être parfaitement cohérente et factuellement fausse. Le rapport le reconnaît dans ses limites, mais les métriques publiées ne sont pas reliées à une vérité terrain ni à un accord humain [S1, p. 18].

Proposition 5 - Validation factuelle par faits atomiques

Élément	Proposition directement exécutable
Objectif	Évaluer la factualité au niveau des affirmations vérifiables plutôt qu’au niveau global de la réponse.
Dispositif	Échantillonner 150 réponses équilibrées entre familles. Décomposer chaque réponse en faits atomiques. Chaque fait reçoit l’un des labels : soutenu, contredit, non vérifiable, ou sans objet. Associer une source et faire annoter en aveugle par deux évaluateurs, avec arbitrage des désaccords.
Mesures	Précision des faits soutenus, erreurs pour 100 tokens, taux de réponses entièrement soutenues, couverture des preuves et accord inter-annotateurs.
Critère de décision	Le score automatique est comparé aux labels humains. Un LLM juge peut assister l’annotation, mais il doit être calibré et ne doit pas être l’unique arbitre [R2-R4].
Livvable	Corpus factuel audité, guide d’annotation et rapport d’accord.
Effort indicatif	6 à 10 jours selon la difficulté des domaines médical et juridique.

Proposition 6 - Cohérence locale et globale

- Cohérence locale : absence de contradiction entre deux phrases voisines.
- Cohérence globale : compatibilité entre conclusion, arguments et contraintes du prompt.
- Cohérence inter-répétitions : absence de conclusions incompatibles entre les dix générations.
- Conformité : respect des consignes, à mesurer séparément de la cohérence.

Un jeu calibré devrait contenir des contradictions franches, des contradictions implicites, des changements de référent, des négations et des conclusions incompatibles. Une cohérence de 1,000 n’est interprétable qu’après réussite sur ce jeu de contrôle.

10. Régimes runtime et effet de la longueur

Le graphique de la page 12 montre une relation visuellement forte entre le volume généré et la latence. Les familles les plus longues, notamment juridique et gouvernance, sont aussi les plus lentes [S1, p. 9-12]. Cette observation est utile, mais elle ne suffit pas à établir des « régimes runtime » propres aux familles.

Formulation prudente proposée

Tant que l’effet de la longueur, de l’entrée et de la charge fournisseur n’est pas neutralisé, parler de « profils descriptifs par famille » est plus défendable que parler de « régimes ».

Proposition 7 - Décomposition de la performance

Élément	Proposition directement exécutable
Objectif	Distinguer la réactivité, la vitesse de génération, la taille des réponses et le post-traitement.
Dispositif	Horodater l’envoi, le premier octet, le premier token, chaque token, la fin du flux, le début et la fin du calcul des métriques, puis la décision de gouvernance. Enregistrer tokens d’entrée et de sortie.
Mesures	TTFT, TPOT/TBT, tokens par seconde, latence totale, post-traitement, longueur d’entrée/sortie et taux d’erreur.
Critère de décision	Estimer une régression de latence sur tokens d’entrée, tokens de sortie et conditions de charge. Rechercher d’éventuels clusters uniquement sur les résidus normalisés, avec stabilité par bootstrap.
Livrable	Table de performance phase par phase et carte des profils corrigés de la longueur.
Effort indicatif	2 à 5 jours, puis collecte continue.

Critères avant d’utiliser le mot « régime »

- Clusters retrouvés sur plusieurs initialisations et plusieurs vagues.
- Séparation non expliquée uniquement par la longueur ou la charge.
- Stabilité des appartenances par bootstrap ou indice d’accord.
- Interprétation opérationnelle claire et action associée.

11. Instrumentation du pipeline et processing time

Le processing time présente une distribution singulière : le P05, la médiane et le P95 sont concentrés autour de 20,02 secondes, alors que la latence varie de 1,7 à 39,18 secondes et qu’un maximum de processing time atteint 87,59 secondes [S1, p. 8]. Cette quasi-constance mérite une clarification technique avant toute interprétation.

Hypothèses possibles, sans conclusion prématurée

Fenêtre fixe de 20 secondes, polling, timeout, tâche asynchrone, arrondi, valeur par défaut ou étape indépendante de l’inférence. Le rapport public ne permet pas de trancher.

Proposition 8 - Journal d’étapes horodaté

Événement	Champ recommandé
Requête prête	t_request_ready
Requête envoyée	t_request_sent
Premier octet	t_first_byte
Premier token visible	t_first_token
Dernier token	t_stream_end
Début / fin métriques	t_metrics_start / t_metrics_end
Décision gouvernance	t_governance_decision
Écriture complète	t_persisted

À partir de ces horodatages, NeoMundi pourra distinguer temps fournisseur, temps de génération, temps de métrologie, temps de gouvernance et temps de persistance. Toute valeur par défaut ou timeout devra être explicitement marquée, et non confondue avec une mesure réelle.

12. Reproductibilité et chaîne de preuve

Le rapport fournit les noms de trois artefacts et leurs empreintes SHA-256, ce qui est utile pour l'intégrité. Cependant, sans accès aux fichiers, aux prompts, aux sorties, au code et à la configuration, une tierce partie ne peut pas reproduire l'analyse [S1, p. 20].

Principe

Un hash prouve qu'un fichier donné n'a pas changé. Il ne remplace ni l'accès au fichier ni les instructions permettant de le régénérer.

Proposition 9 - Paquet minimal reproductible

Chemin	Contenu
manifest.json	Versions, hashes, nombre de lignes, licences et description des artefacts.
config/run.yaml	Endpoint, modèle, paramètres, date, langue, limites et options de sécurité.
prompts/prompts.csv	Prompt ID, version, famille, texte complet et métadonnées.
raw/responses.jsonl	Réponse brute, horodatages, identifiants et métadonnées fournisseur.
derived/metrics.parquet	Scores calculés, flags, raisons et versions.
scripts/	Calcul des métriques, nettoyage, agrégation et génération du rapport.
environment/	Lockfile, image Docker ou instructions exactes de l'environnement.
tests/	Tests unitaires, contrôles positifs et résultats attendus.
README.md	Commande unique de reproduction et limites connues.

Élément	Proposition directement exécutable
Objectif	Permettre une réplication indépendante sur un sous-ensemble puis sur le corpus complet.
Dispositif	Publier un paquet redigé des données sensibles. Demander à un tiers de reconstruire les tableaux 6 à 10 sans aide orale, à partir du README.
Mesures	Égalité des hashes, nombre de lignes, scores recalculés à tolérance définie, figures identiques et journal d'écarts.
Critère de décision	Réussite si un tiers reconstruit le rapport avec une seule commande et documente tout écart.
Livrable	Release v1.0-repro et rapport de réplication signé.
Effort indicatif	3 à 7 jours selon l'état du code.

13. Identité du modèle et provenance API

Le rapport indique « modèle demandé : kimi-k3 » et « modèle observé : kimi-k3 ». Cette symétrie confirme le libellé renvoyé ou enregistré, mais ne garantit pas à elle seule la révision exacte du modèle servi [S1, p. 1, 5 et 14].

Proposition 10 - Fiche d'identité d'exécution

Champ	Exemple de statut
Fournisseur et endpoint	Obligatoire.
Identifiant demandé / renvoyé	Obligatoire.
Révision ou deployment ID	À enregistrer si exposé.
Empreinte système fournisseur	À enregistrer si exposée.
Prompt système et outils	Version hashée et archivée.
Température, top_p, seed	Obligatoires, avec valeurs nulles explicites.
Max tokens et stop sequences	Obligatoires.
Mode de raisonnement / sécurité	Obligatoire lorsque disponible.
Tokeniseur ou source du comptage	Obligatoire.
Limite de vérification	Si la révision n'est pas exposée : "identité déclarée par le fournisseur uniquement".

Cette transparence protège également NeoMundi : lorsqu'un fournisseur modifie silencieusement un déploiement, le rapport peut distinguer une dérive du modèle d'une dérive de la métrique.

14. Validation longitudinale et détection de dérive

NeoMundi reconnaît qu’une seule vague ne démontre pas la stabilité à long terme [S1, p. 18]. Cette limite est correctement formulée et peut être transformée en programme longitudinal léger.

Proposition 11 - Vague ancrée sur huit semaines

Élément	Proposition directement exécutable
Objectif	Détecter les changements de modèle, d’API, de métrique ou de comportement.
Dispositif	Sélectionner 24 prompts ancrés couvrant les 12 familles et 12 prompts rotatifs. Exécuter chaque semaine 5 répétitions dans une fenêtre horaire stable. Archiver les métadonnées de fournisseur et les versions de mesure.
Mesures	Médianes et intervalles par prompt, contradiction rate, factualité, TTFT, TPOT, FLAG/WARN et empreintes de distribution.
Critère de décision	Définir une baseline sur deux vagues. Déclencher une investigation en cas de changement au-delà d’un seuil pré-enregistré ou de rupture détectée sur plusieurs métriques.
Livrable	Tableau longitudinal, journal de changements et fiche d’investigation.
Effort indicatif	Environ 180 générations par semaine.

Bénéfice

Cette vague courte permet de distinguer une amélioration réelle, une régression du fournisseur, une modification du normalisateur et un simple bruit d’échantillonnage.

15. Plan d'exécution sur 30 jours

Période	Chantier	Résultat attendu
J1-J3	Métrologie	Dictionnaire des métriques, formules, tests unitaires, événements du pipeline.
J4-J7	Jeux contrôlés	Cas propres, contradictions, erreurs factuelles, incidents techniques, guide d'annotation.
J8-J12	Calibration	Double annotation, accord, seuils sur développement et validation.
J13-J17	Test aveugle	Matrice de confusion, sensibilité, invariance, faux positifs et faux négatifs.
J18-J21	Répétitions	Analyse intra-prompt du corpus Kimi K3 et sous-protocole multi-température.
J22-J24	Runtime	TTFT, TPOT, résidualisation de la longueur et requalification des profils.
J25-J27	Reproductibilité	Paquet minimal, commande de reproduction, réplication par un tiers.
J28-J30	Rapport v2	Résultats, limites, critères d'acceptation et plan longitudinal.

Ordre recommandé

Il est préférable de valider d'abord les instruments avant de lancer de nouveaux baromètres. Accumuler davantage de données avec des métriques non calibrées augmente le volume d'observations, mais pas nécessairement la connaissance.

Quick wins en 72 heures

Publier les paramètres de génération, inclure le prompt complet dans l'exemple reconstituable, renommer provisoirement les « régimes » en « profils », ajouter WARN et documenter la nature exacte du processing time.

16. Critères d’acceptation et formulations recommandées

Tableau de sortie de validation

Axe	Critère minimal de sortie
Définitions	100 % des métriques disposent d’une fiche et d’un exemple recalculable.
Sensibilité	Réaction monotone aux dégradations ciblées et absence de saturation non justifiée.
Accord humain	Accord documenté, avec désaccords et arbitrages conservés.
ALLOW / FLAG	Matrice de confusion sur test aveugle et seuils verrouillés.
Répétitions	Résultats par prompt, intervalles et contradictions inter-répétitions.
Factualité	Vérité terrain sourcée et faits non vérifiables séparés des faits faux.
Runtime	TTFT, TPOT, débit et post-traitement séparés.
Reproductibilité	Rapport reconstruit par un tiers à partir du paquet publié.
Modèle	Identité et paramètres suffisamment documentés, ou limite explicite.
Longitudinal	Baseline et seuils de dérive pré-enregistrés.

Trois reformulations éditoriales immédiates

Formulation actuelle	Formulation provisoire plus robuste
« Plusieurs régimes runtime apparaissent »	« Plusieurs profils descriptifs par famille apparaissent, sous réserve de neutraliser l’effet de la longueur et de la charge. »
« Exemple de preuve runtime restructurable »	« Exemple de trace runtime », tant que le prompt complet et les artefacts ne sont pas accessibles.
« Cohérence moyenne : 1,000 »	« Score de cohérence v3.0.0 : 1,000 sur ce corpus, métrique en cours de calibration publique. »

Ces changements ne diminuent pas la valeur du travail. Ils alignent simplement le niveau d’affirmation sur le niveau actuel de preuve accessible.

17. Conclusion

Le rapport Kimi K3 montre une capacité réelle de collecte, de traçabilité et d'organisation des observations runtime. Il contient également plusieurs réflexes méthodologiques sains : périmètre limité, dimensions séparées, limites explicites et absence de score global triomphaliste.

Le renforcement prioritaire concerne la métrologie elle-même. Pour soutenir les termes stabilité, cohérence, factualité, invariant ou gouvernance, NeoMundi doit démontrer que ses scores sont définis, sensibles, calibrés, comparés à une vérité terrain et reproductibles. Les protocoles proposés dans cet audit permettent de franchir cette étape sans reconstruire toute l'architecture.

Appréciation finale

La base technique est intéressante. La méthode peut devenir difficilement contestable si NeoMundi transforme ses scores propriétaires en instruments soumis à des contrôles connus, à un test aveugle et à une réplique indépendante.

Cet audit recommande donc une consolidation progressive, non une remise à zéro : conserver la traçabilité existante, exploiter réellement les répétitions, instrumenter chaque phase, calibrer les métriques et publier un paquet reproductible.

Stéphane Gorius - R&D AIzyNow - Audit indépendant réalisé à titre gracieux.

A. Annexe opérationnelle - Matrice de contrôles

Dimension	Contrôle négatif	Contrôle positif	Cas limite
Cohérence	Réponse sans contradiction	Contradiction explicite	Contradiction implicite ou changement de référent
Factualité	Faits sourcés exacts	Date ou nombre faux	Affirmation invérifiable présentée comme certaine
Consignes	Toutes les contraintes respectées	Une contrainte prioritaire violée	Conflit de contraintes correctement signalé
Stabilité	Même conclusion, formulations variées	Conclusions opposées	Même conclusion mais chiffres différents
Sécurité	Refus justifié	Instruction dangereuse exécutée	Réponse ambiguë nécessitant abstention
Runtime	Réponse courte et rapide	Latence réseau injectée	Réponse longue à contenu équivalent
Flux	Streaming complet	Flux interrompu	Métadonnées manquantes ou doublon

Schéma minimal de ligne de vérité terrain

Champ	Description
case_id	Identifiant stable.
dimension	Cohérence, factualité, sécurité, etc.
prompt	Texte complet et version.
response	Sortie évaluée.
gold_label	ALLOW, WARN, FLAG ou ABSTAIN.
fault_type	Type d'anomalie contrôlée.
severity	Faible, moyenne, élevée, critique.
evidence	Source ou justification du label.
annotator_1 / 2	Labels indépendants.
adjudication	Décision finale et motif.
split	Développement, validation ou test aveugle.

B. Annexe - Questions à documenter dans une version ultérieure

Les réponses à ces questions, si elles sont fournies par NeoMundi, permettront de reclasser plusieurs axes actuellement considérés comme insuffisamment documentés vers la catégorie des éléments solides à conserver, ou de cibler précisément les expériences complémentaires encore nécessaires.

1. Quelle est la formule exacte du `stability_score` et pourquoi sa valeur dominante est-elle 0,923077 ?
2. Quel dispositif produit `coherence_score` = 1,000 sur toutes les observations ?
3. Le `factual_hallucination_score` distingue-t-il “aucun fait”, “fait vrai” et “fait non vérifiable” ?
4. Comment les seuils WARN et FLAG ont-ils été choisis, et sur quel corpus ?
5. Quel composant décide que la réponse « paraît correcte » dans l'exemple de la page 15 ?
6. Que mesure précisément `processing_time_ms` et pourquoi sa distribution est-elle concentrée autour de 20 secondes ?
7. Quelles étaient les valeurs de température, `top_p`, `seed`, `max_tokens` et prompt système ?
8. Le même modèle ou fournisseur est-il utilisé pour générer et pour évaluer ?
9. Les dix répétitions sont-elles indépendantes et exécutées dans quelles conditions de charge ?
10. Les artefacts CSV/JSON et les scripts peuvent-ils être fournis dans une version expurgée ?

Bibliographie et références

[S1] NeoMundi Observatory. Rapport d’observation runtime - Kimi K3. Version 1.0, 22 juillet 2026.

[R1] Min, S. et al. FactScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation. EMNLP 2023. arXiv:2305.14251.

[R2] Jung, J., Brahman, F., Choi, Y. Trust or Escalate: LLM Judges with Provable Guarantees for Human Agreement. 2024. arXiv:2407.18370.

[R3] Chen, G. H. et al. Humans or LLMs as the Judge? A Study on Judgement Biases. 2024. arXiv:2402.10669.

[R4] Wei, H. et al. Systematic Evaluation of LLM-as-a-Judge in LLM Alignment Tasks. 2024. arXiv:2408.13006.

[R5] NIST. Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile. NIST AI 600-1, 2024.

[R6] MLCommons. MLPerf Inference 5.1: benchmarking LLM inference with TTFT and TPOT, 2025.

[R7] Revealing the Value of Multiple Generations in Benchmark Evaluation of Large Language Models. 2025. arXiv:2502.08943.

[R8] Gupta, A. et al. ReliabilityBench: Evaluating LLM Agent Reliability Under Repeated Execution, Perturbation and Tool Failures. 2026. arXiv:2601.06112.

[R9] Huang, X. et al. Consistency in Language Models: Current Landscape, Challenges, and Future Directions. 2025. arXiv:2505.00268.

Liens utiles

[FactScore](#)

[Trust or Escalate](#)

[NIST AI 600-1](#)

[MLPerf Inference](#)

[ReliabilityBench](#)

Fin du document - Version 1.1 finale